RÉFÉRENTIEL TECHNIQUE DES PIPELINES BATCH GCP

Cadre d'Ingénierie, Architecture Modulaire & Spécifications des 5 Pipelines End-to-End | **Auteur :** FOFANA Lazeny

1. DÉMARCHE EN 5 MODULES DÉCOUPLÉS

• **01_ingestion :** Extraction Python, typage strict, rejet motivé et 12 tests unitaires automatisés (pytest).
• **02_data_lake :** Cloud Storage partitionné Hive (annee=YYYY/mois=MM/jour=DD/) et table externe BigQuery.
• **03_serverless :** Cloud Functions Gen 2 managées, déclenchement Cloud Scheduler sous jetons OIDC, script deployer.sh.
• **04_entrepot :** BigQuery Native Table avec partitionnement DATE et clustering. Ingestion par MERGE SQL idempotent.
• **05_restitution :** Vues analytiques dénormalisées, KPIs de reporting et connecteur direct Looker Studio.

2. LES 4 CONTRÔLES NON-NÉGOCIABLES

• **Idempotence absolue :** Rejouer une exécution à l'infini produit exactement le même état final. Zéro doublon en base, chemins GCS déterministes.
• **Typage & Rejets tracés :** Conversion systématique à la source (TIMESTAMP UTC, NUMERIC). Rejets isolés dans un fichier d'audit dédié.
• **Sécurité & Secrets :** Zéro clé d'API en clair dans les dépôts. Secret Manager, variables .env locales et .gitignore étanche.
• **Testabilité & Observabilité :** Pytest systématique avant tout déploiement, vérification des codes HTTP et logs structurés Cloud Logging.

3. SPÉCIFICATIONS DES 5 GRANDS PIPELINES END-TO-END DE PRODUCTION

N°	Pipeline End-to-End	Source & Données	Stack GCP	Défi d'Ingénierie & Patterns Clés	Critères de Validation

01	**Pipeline 1 — Météo**
	✔ **EN PRODUCTION**
		API Open-Meteo
		(Relevés horaires météo)
			`Cloud Storage`
			`Cloud Functions G2`
			`Cloud Scheduler`
			`BigQuery`
				Socle Serverless End-to-End : Ingestion batch, partitionnement Hive annee=/mois=/jour=/, table externe GCS, chargement par MERGE SQL dédoublonnant sur clé primaire composite (station_id, date_heure).	• 12 tests pytest validés
					• Idempotence GCS et BQ vérifiée
					• Déploiement deployer.sh OK

02	**Pipeline 2 — Données Financières**
	À venir
		API Crypto / Marchés
		(CoinGecko, Alpha Vantage)
			`Secret Manager`
			`Cloud Storage`
			`Cloud Functions`
			`BigQuery`
				Sécurité & Quotas API : Récupération dynamique sous Google Secret Manager, gestion de débit strict (rate limiting) et mécanisme de repli exponentiel (Exponential Backoff) sur code HTTP 429.	• Zéro clé en clair dans le code
					• Résilience réseau testée
					• Table native partitionnée DATE

03	**Pipeline 3 — Mobilité & Flux Paginés**
	À venir
		API Dynamique Paginée
		(Vélib' Métropole / OpenData)
			`Cloud Storage`
			`Cloud Functions`
			`BigQuery`
				Pagination & Fragmentation : Parcours automatique de catalogues paginés par curseur et offset, condition d'arrêt déterministe, découpage en micro-lots GCS de taille bornée sans saturation mémoire.	• Exhaustivité du catalogue validée
					• Découpage micro-lots conforme
					• Plafond MAX_PAGES étanche

04	**Pipeline 4 — Entrepôt Évolutif** *À venir*	Référentiels & Transactions (Formats JSON semi-structurés)	`BigQuery SQL DML` `(STRUCT & REPEATED)`	**Historisation SCD2 & Structures Imbriquées :** Modélisation de dimensions à évolution lente (SCD Type 2 avec date_debut, date_fin, est_actif), et gestion de structures imbriquées avec UNNEST().	• Unicité stricte de version active • Historique complet sans trou • Requêtes analytiques sans jointures
05	**Pipeline 5 — Réconciliation & BI** *À venir*	Flux Multi-Sources Hétérogènes (Météo horaire + Mobilité)	`BigQuery SQL` `Looker Studio`	**Modélisation Multidimensionnelle Conforme :** Réconciliation de grains spatio-temporels distincts via dimension conforme, détection de corrélation, vues analytiques agrégées et dashboard de restitution Looker Studio.	• Clés conformes certifiées • Dashboard Looker live connecté • Table de contrôle d'anomalies

4. TECHNIQUES & STANDARDS TRANSVERSES DE PRODUCTION

• **Optimisation Mémoire & Streaming :** Traitement streaming par générateur Python (yield) en mémoire bornée (< 256 Mo), compression GZIP au fil de l'eau pour absorber les gros volumes sans crash mémoire.
• **Format Colonnaire Parquet :** Écriture optimisée Parquet / Snappy avec partitionnement physique Hive pour minimiser les octets scannés et les coûts d'interrogation BigQuery.
• **Reprise d'Historique & Backfill :** Automatisation de rejeu par fenêtre temporelle glissante, table journal d'exécution et gestion de filigrane (Watermark CDC) sur updated_at.
• **Déploiement IaC & CI/CD :** Déploiements idempotents via Cloud SDK (gcloud), gestion stricte des identités IAM et validation par tests unitaires automatisés avant tout push.